

$$\varepsilon_1^2 = \sum_i (y_i - \beta_0)^2 \xrightarrow{\partial/\partial \beta_0 = 0} \sum_i -2(y_i - \beta_0) = 0 \quad (1) \text{ الف:}$$

$$\Rightarrow \sum_i y_i = n\beta_0 \Rightarrow \boxed{\beta_0 = \frac{\sum_i y_i}{n} = \bar{y}} = 59,6$$

$$\varepsilon_1^2 = \sum_i (y_i - \beta_1 x_i)^2 \xrightarrow{\partial/\partial \beta_1 = 0} \sum_i -2x_i(y_i - \beta_1 x_i) = 0 \quad (1) \text{ ب:}$$

$$\Rightarrow \sum_i x_i y_i = \sum_i \beta_1 x_i \Rightarrow \overline{xy} = \beta_1 \bar{x} \Rightarrow \boxed{\beta_1 = \frac{\overline{xy}}{\bar{x}}} = \frac{9774}{146} = 66.94$$

(1) ج: معادله اول بیانگر "رگرسیون خطی" است که رابطه بین متغیر X و میانگین متغیر Y را نشان می‌دهد.

اما معادله دوم بیانگر رابطه میانگین متغیر X و متغیر Y است. نتایجی که دو معادله اول صحت می‌دهند

نیز در معادله دوم صحت می‌دهند (بدون وجود error term). معادله اول، با نام β_0 و β_1

صورت مستقیم از داده‌ها بدست می‌آیند، اما در معادله دوم β_0 و β_1 استفاده اند

$$\sigma^2 = \frac{1}{n-2} \sum_i (\hat{y}_i - y_i)^2 \quad (1) \text{ د:}$$

$$y = \beta_0 + \beta_1 x + \varepsilon_1 \Rightarrow \varepsilon_1^2 = \sum_i (y_i - \beta_0 - \beta_1 x_i)^2$$

$$\frac{\partial}{\partial \beta_0} = 0 \Rightarrow \sum_i -2(y_i - \beta_0 - \beta_1 x_i) = 0 \Rightarrow \sum_i y_i - n\beta_0 - \beta_1 \sum_i x_i = 0$$

$$\Rightarrow n\bar{y} - n\beta_0 - n\beta_1 \bar{x} = 0 \Rightarrow \bar{y} = \beta_0 + \beta_1 \bar{x} \quad \textcircled{I}$$

$$\frac{\partial}{\partial \beta_1} = 0 \Rightarrow \sum_i -2x_i(y_i - \beta_0 - \beta_1 x_i) = 0 \Rightarrow \sum_i x_i y_i - \beta_0 \sum_i x_i - \beta_1 \sum_i x_i^2 = 0$$

$$\sum_i x_i y_i - \beta_0 \sum_i x_i - \beta_1 \sum_i x_i^2 = 0 \Rightarrow \overline{xy} - \beta_0 \bar{x} - \beta_1 \overline{x^2} = 0 \quad \textcircled{II}$$

$$(\bar{y} = \beta_0 + \beta_1 \bar{x}) \times \bar{x} = \beta_0 \bar{x} = \bar{x} \bar{y} - \beta_1 (\bar{x})^2 \quad \text{با استفاده از (I) و (II) داریم}$$

$$\bar{x} \bar{y} - \beta_0 \bar{x} - \beta_1 \bar{x}^2 = 0$$

$$\Rightarrow \bar{x} \bar{y} - \bar{x} \bar{y} + \beta_1 (\bar{x})^2 - \beta_1 \bar{x}^2 = 0 \Rightarrow \beta_1 = \frac{\bar{x} \bar{y} - \bar{x} \bar{y}}{\bar{x}^2 - (\bar{x})^2}$$

$$\Rightarrow \beta_1 = \frac{977.4 - 870.16}{2498 - 213.16} = \frac{107.24}{36.64} = 2.92$$

$$\Rightarrow \beta_0 = \bar{y} - \beta_1 \bar{x} = 59.6 - 2.92(14.6) = 16.96$$

$$\Rightarrow \hat{y} = 2.92x + 16.96$$

x:	5	11	18	15	21	6	17
\hat{y} :	31.56	49.8	69.52	60.76	78.28	34.48	66.6
$ \hat{y} - y $:	2.44	2.8	3.52	8.76	1.72	0.52	0.6

x:	10	24	19
\hat{y} :	46.16	87.04	72.44
$ \hat{y} - y $:	1.84	0.04	8.56

$$\Rightarrow S^2 = \frac{1}{8} (183.1712) = 22.89$$

(1) هـ: بعد از دیتا نویسی در اکسل، درایع یک تنوع نرمال با

میانگین \hat{y} خواهد بود.

2. الف: مفرد L_1 -regularization و L_2 -regularization برای جریه کردن وزن ها در

دگرسیون خطی هستند. بیانات دیگر loss-function در این حالت برابر خواهد بود با:

$$\sum_{i=1}^n (y_i - w_i x_i)^2 + \lambda \sum_i |w_i| \quad (\text{for } L1)$$

$$\sum_{i=1}^n (y_i - w_i x_i)^2 + \lambda \sum_i w_i^2 \quad (\text{for } L2)$$

علا نظر که دیده میشود در $L1$ ، مجموع تدریقات وزن ها لحاظ میشود، در حالی که $L2$ مجموع

مربعات با لحاظ میشود در نتیجه $L1$ منتهج به مدل Sparse میشود.

$$\hat{\beta} = \frac{\partial}{\partial \beta} [\|A\beta - Y\|_2^2 + \lambda \| \beta \|_2^2]$$

2 ب:

where: $A = \begin{bmatrix} \leftarrow x_1^T \rightarrow \\ \vdots \\ \leftarrow x_n^T \rightarrow \end{bmatrix}_{n \times d}$ و $\beta = \begin{bmatrix} \beta_0 \\ \vdots \\ \beta_d \end{bmatrix}_{d \times 1}$

$$\Rightarrow \hat{\beta} = \frac{\partial}{\partial \beta} [(A\beta - Y)^T (A\beta - Y) + \lambda \beta^T \beta] =$$

$$\frac{\partial}{\partial \beta} [(B^T A^T - Y^T)(A\beta - Y) + \lambda \beta^T \beta] =$$

$$\frac{\partial}{\partial \beta} [B^T A^T A \beta - 2Y^T A \beta + Y^T Y + \lambda \beta^T \beta] =$$

$$2A^T A \beta - 2A^T Y + 2\lambda \beta = 0$$

$$\Rightarrow (A^T A + \lambda I) \beta = A^T Y \rightarrow \beta = (A^T A + \lambda I)^{-1} A^T Y$$

Subject:

Year. Month. Date. ()

3. الف: اگر w_i واحد داخل بردار وزن بگیریم:

$$X = \begin{bmatrix} x_1 \\ \vdots \\ x_d \end{bmatrix} \quad w_i = \begin{bmatrix} w_{i1} \\ \vdots \\ w_{id} \end{bmatrix}$$

$$P(Y=y_i | X) \propto \exp(w_i^T X) \Rightarrow P(Y=y_i | X) = \beta \exp(w_i^T X)$$

حرف یا متن β است. از آنجا که جمع تمامی احتمال ها 1 میشود:

$$\sum_{i=1}^K P(Y=y_i | X) = 1 \Rightarrow \beta \left[\sum_{i=1}^{K-1} \exp(w_i^T X) \right] + P(Y=y_K | X) = 1$$

$$\Rightarrow \beta = \frac{1 - P(Y=y_K | X)}{\sum_{i=1}^{K-1} \exp(w_i^T X)}$$

برای یافتن $P(Y=y_K | X)$ ، می‌توانیم از logistic regression استفاده کنیم بنحوی که

$K-1$ کلاس را + و کلاس K ام را - در نظر بگیریم:

$$\sum_{i=1}^{K-1} P(Y=y_i | X) = \frac{1 + P(Y=y_K | X)}{1 + \sum_{i=1}^{K-1} \exp(w_i^T X)}$$

$$P(Y=y_K | X) = \frac{\sum_{i=1}^{K-1} \exp(w_i^T X)}{1 + \sum_{i=1}^{K-1} \exp(w_i^T X)}$$

$$\Rightarrow \beta = \frac{1 - P(Y=y_K | X)}{\sum_{i=1}^{K-1} \exp(w_i^T X)} = \frac{1}{1 + \sum_{i=1}^{K-1} \exp(w_i^T X)}$$

حال که β بدست آمد، می‌توان نوشت:

$$P(Y=y_i | X) = \frac{\exp(w_i^T X)}{1 + \sum_{i=1}^{K-1} \exp(w_i^T X)} \quad 1 \leq i \leq K-1$$

Subject:

Year: Month: Date: ()

3. ب: با مقایسه $P(Y=y_i | X)$ به ازای تمام i ها، آن i را می‌گزینیم که مقدار

احتمال را بیشینه می‌کند. انتخاب می‌کنیم:

$$\hat{i} = \arg \max_i P(Y=y_i | X)$$

5) ویژگی‌های Distance metric:

① $D(a, b) \geq 0$

② $D(a, b) = 0 \iff a = b$

③ $D(a, b) = D(b, a)$

④ $D(a, b) + D(b, c) \geq D(a, c)$

با ضرب شدن تمام feature ها در عدد β داریم:

$$D_{\text{new}}(a, b) = \sqrt{\beta^2 \sum_{k=1}^d (a_k - b_k)^2} = |\beta| \sqrt{\sum_{k=1}^d (a_k - b_k)^2}$$

حال داریم:

① $D_{\text{new}}(a, b) \geq 0$

$$D_{\text{new}}(a, b) = 0 \Rightarrow |\beta| \sqrt{\sum_{k=1}^d (a_k - b_k)^2} = 0 \quad \text{و چون } \beta \neq 0 \Rightarrow$$

$$\sum_{k=1}^d (a_k - b_k)^2 = 0 \Rightarrow a_k = b_k \quad \forall k \Rightarrow a = b \quad \text{طرف اول}$$

② ویژگی: اثبات شد \Rightarrow طرف دوم $a = b \Rightarrow D_{\text{new}}(a, b) = 0$

③ ویژگی: اثبات شد $D_{\text{new}}(a, b) = D_{\text{new}}(b, a)$ این نتیجه گیری به وقوع

دست است، و نتیجه ③ نیز اثبات شد.

Subject :

Year . Month . Date . ()

برای دیدنی 4 نیز داریم : در مزیل فاصله افلاکسی ، این دیدنی برقرار است .

$$\sqrt{\sum_1 (a_k - b_k)^2} + \sqrt{\sum_1 (b_k - c_k)^2} \geq \sqrt{\sum_1 (a_k - c_k)^2} \quad \text{بباید دیدنی}$$

حال اگر طرفین رابطه را در $|B|$ ضرب کنیم نیز می توان رابطه برقرار است .

$$\underbrace{|B| \sqrt{\sum_1 (a_k - b_k)^2}}_{D_{\text{new}}(a, b)} + \underbrace{|B| \sqrt{\sum_1 (b_k - c_k)^2}}_{D_{\text{new}}(b, c)} \geq \underbrace{|B| \sqrt{\sum_1 (a_k - c_k)^2}}_{D_{\text{new}}(a, c)}$$

دیدنی دیدنی (IV) نیز اثبات شد .

(4) انت:

$$E[P_n(x)] = \frac{1}{nh_n} \left[\sum_{i=1}^n E\left(\phi\left(\frac{x-x_i}{h_n}\right)\right) \right] =$$

$$\frac{1}{h_n} E\left(\phi\left(\frac{x-x_i}{h_n}\right)\right) = \int_{-\infty}^{\infty} \frac{1}{h_n} \phi\left(\frac{x-x_i}{h_n}\right) P(x_i) dx_i$$

$$P(x_i) = \frac{1}{\sqrt{2\pi}\sigma'} \exp\left\{-\frac{1}{2}\left(\frac{x_i-\mu}{\sigma'}\right)^2\right\}$$

می‌توانیم:

$$\phi(x) = \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}(x-0)^2\right\} \Rightarrow$$

$$\phi\left(\frac{x-x_i}{h}\right) = \frac{1}{\sqrt{2\pi}h} \exp\left\{-\frac{1}{2}\left(\frac{x-x_i}{h}\right)^2\right\}$$

$$\rightarrow E[P_n(x)] = \int \frac{1}{2\pi\sigma'h_n} \exp\left\{-\frac{1}{2}\left[\left(\frac{x_i-\mu}{\sigma'}\right)^2 + \left(\frac{x-x_i}{h}\right)^2\right]\right\} dx_i$$

حل باید انتگرال را حساب کنیم:

$$e^{-\frac{1}{2}\left(\frac{x_i^2}{\sigma'^2}\right)} \times e^{-\frac{1}{2}\left(\frac{\mu^2}{\sigma'^2}\right)} \times e^{\frac{x_i\mu}{\sigma'^2}} \times e^{-\frac{1}{2}\left(\frac{x^2}{h^2}\right)} \times e^{-\frac{1}{2}\left(\frac{x_i^2}{h^2}\right)} \times e^{\frac{xx_i}{h^2}}$$

$$\rightarrow E[P_n(x)] = \frac{1}{2\pi\sigma'h_n} \exp\left\{-\frac{1}{2}\left(\frac{\mu^2}{\sigma'^2}\right) - \frac{1}{2}\left(\frac{x^2}{h^2}\right)\right\}$$

$$\times \int \exp\left\{-\frac{1}{2}x_i^2\left(\frac{1}{\sigma'^2} + \frac{1}{h^2}\right) + x_i\left(\frac{x}{h^2} + \frac{\mu}{\sigma'^2}\right)\right\} dx_i$$

برای آنکه انتگرال بالا بصورت مربع کامل در بیاید، باید تغییر متغیر انجام دهیم:

$$\sigma^2 = \frac{\sigma^2 \cdot h^2}{\sigma^2 + h^2}$$

$$\frac{\sigma^2 \cdot h^2}{\sigma^2 + h^2}$$

$$\frac{1}{\sigma^2} = \frac{1}{\frac{1}{h_n^2} + \frac{1}{\sigma^2}}$$

$$\Rightarrow E[P_n(x)] =$$

$$u = \sigma^2 \left(\frac{n}{h_n^2} + \frac{\mu}{\sigma^2} \right)$$

$$\frac{1}{2\pi\sigma h_n} \exp\left\{-\frac{1}{2}\left(\frac{\mu^2}{\sigma^2} + \frac{n^2}{h_n^2} - \frac{u^2}{\sigma^2}\right)\right\} \cdot \int \exp\left(-\frac{1}{2}\left(\frac{n_i - u}{\sigma}\right)^2\right) da_i$$

فیت توزیع گاوسی

$$m = \frac{n_i - u}{\sigma} \Rightarrow da_i = \sigma dm = \sigma \int \exp\left(-\frac{m^2}{2}\right) dm$$

$$\Rightarrow E[P_n(x)] = \frac{\sqrt{2\pi}\sigma}{2\pi\sigma h_n} \exp\left\{-\frac{1}{2}\left(\frac{\mu^2}{\sigma^2} + \frac{n^2}{h_n^2} - \frac{u^2}{\sigma^2}\right)\right\}$$

$$\frac{1}{\sqrt{2\pi} \times \sqrt{\sigma^2 + h^2}}$$

$$\frac{-u^2}{\sigma^2} = -\sigma^2 \left(\frac{n}{h_n^2} + \frac{\mu}{\sigma^2} \right)^2 = \frac{-\sigma^2 h_n^2}{\sigma^2 + h_n^2} \left(\frac{n\sigma^2 + \mu h_n^2}{h_n^2 \sigma^2} \right)^2$$

$$= \frac{-(n\sigma^2 + \mu h_n^2)^2}{h_n^2 \sigma^2 (\sigma^2 + h_n^2)}$$

$$\Rightarrow \exp\left\{-\frac{1}{2}\left(\frac{1}{\sigma^2 h_n^2} (n^2 (h_n^2 + \sigma^2) - \frac{(n\sigma^2 + \mu h_n^2)^2}{\sigma^2 + h_n^2})\right)\right\}$$

$$= \exp\left\{-\frac{1}{2}\left(\frac{1}{\sigma^2 h_n^2} \left(\frac{n h_n \sigma - \mu h_n \sigma}{h_n^2 + \sigma^2}\right)^2\right)\right\} =$$

$$\exp\left\{-\frac{1}{2}\left(\frac{n - \mu}{h_n^2 + \sigma^2}\right)^2\right\}$$

Subject:

Year:

Month:

Date:

()

$$E[P_n(n)] = \overline{P_n(n)} =$$

وین در آخر داریم:

$$\frac{1}{\sqrt{2\pi} \sqrt{h_n^2 + \sigma^2}} \exp\left\{-\frac{1}{2} \left(\frac{n-\mu}{h_n^2 + \sigma^2}\right)^2\right\} = N(\mu, h_n^2 + \sigma^2)$$

(4) ب: در مرحله قبل نشان دادیم:

$$\overline{P_n(n)} = \frac{1}{\sqrt{2\pi} \sqrt{\sigma^2 + h_n^2}} \exp\left\{-\frac{1}{2} \left(\frac{n-\mu}{h_n^2 + \sigma^2}\right)^2\right\}$$

$$P(n) = \frac{1}{\sqrt{2\pi} \sigma} \exp\left\{-\frac{1}{2} \left(\frac{n-\mu}{\sigma}\right)^2\right\} \quad \text{از طرفی } P(n) \text{ نیز برابر است با:}$$

حال با فالتورگیری از $P(n)$ داریم:

$$P(n) - \overline{P_n(n)} = P(n) \left[1 - \frac{\sigma}{\sqrt{\sigma^2 + h_n^2}} \exp\left\{-\frac{1}{2} \frac{(n-\mu)^2 h_n^2}{\sigma^2 (h_n^2 + \sigma^2)}\right\} \right]$$

با در نظر گرفتن اینکه h_n مقدار کوچکی است:

$$P(n) - \overline{P_n(n)} \sim P(n) \cdot \frac{h_n}{2\sigma^2} \left[1 - \left(\frac{n-\mu}{\sigma}\right)^2 \right]$$