

(1) این: u_1 و u_2 برتیب component ها

حاصل از PCA هستند. label داده ها

در نحوه ترس component ها PCA موثر نیست زیرا

PCA یک روش unsupervised است که در آن وابستگی تقویری داده ها بری component


باید بسط شود. به عبارت دیگر، معادله زیر جواب برای (\vec{u}, λ)

$$S S u = \lambda u$$

دارد و آن \vec{u} ای انتخاب می شود که مقدار ویژه λ است. بسط باشد. (یعنی اثری از y_i در

$$S u = \lambda u \quad \text{و} \quad S = \frac{1}{n} \sum_{i=1}^n x_i x_i^T$$

معادله زیر بنویسید.




(1) ب: حالت اول: 2D data, 100% error

1D data 0% error

همانطور که دیده می شود، با این نوع بسط بندی در فضا

2 بندی، خطی بین 1NN با دقت 0 درصد (خطای 100 درصد) برآورد داده خواهد نمود. اما چنانچه

هین داده ها بری محور اول PCA (\vec{u}_1) تقویر شوند، خطی بین 1NN دقت 100% خواهد داشت.



حالت دوم: 2D data 0% error

1D data 100% error

با این نوع بر حسب گذاری، خطی بین 1NN به دقت

100% میرسد، اما در حالتی که داده ها بری \vec{u}_1 تقویر شوند، نزدیکترین نمونه به هر x_i یک

نمونه با بر حسب - خواهد بود. (توجه: نزدیک PCA به label نمونه ها)

Subject,

Year. Month. Date. ()

$$S_1^2 = \sum_{y_i \in Y_1} (y_i - m_1)^2 = \sum_{y_i \in Y_1} y_i^2 + \sum_{y_i \in Y_1} m_1^2 - 2 m_1 \sum_{y_i \in Y_1} y_i \quad (2)$$

$$\Rightarrow \frac{1}{n_1} S_1^2 = \frac{1}{n_1} \sum_{y_i \in Y_1} y_i^2 + m_1^2 - 2 m_1 \left(\frac{1}{n_1} \sum_{y_i \in Y_1} y_i \right) =$$
$$\frac{1}{n_1} \sum_{y_i \in Y_1} y_i^2 - m_1^2 \quad (m_1 \text{ بتعريف})$$

$$\frac{1}{n_2} S_2^2 = \frac{1}{n_2} \sum_{y_j \in Y_2} y_j^2 - m_2^2 \quad \text{بهمین ترتیب برای } \frac{1}{n_2} S_2^2 \text{ هم داریم:}$$

$$\Rightarrow (m_1 - m_2)^2 + \frac{1}{n_1} S_1^2 + \frac{1}{n_2} S_2^2 = \frac{1}{n_1} \sum_{y_i \in Y_1} y_i^2 + \frac{1}{n_2} \sum_{y_j \in Y_2} y_j^2$$

$$- 2 \frac{1}{n_1} \sum_{y_i \in Y_1} y_i \times \frac{1}{n_2} \sum_{y_j \in Y_2} y_j = \frac{1}{n_1} \sum_{y_i \in Y_1} y_i^2 + \frac{1}{n_2} \sum_{y_j \in Y_2} y_j^2$$
$$- 2 m_1 m_2 \quad - \frac{2}{n_1 n_2} \sum_{y_i \in Y_1} \sum_{y_j \in Y_2} y_i y_j$$

ادامه در صفحه بعد

عبارت صنف قبل را می توان بلونه ای بنویس داد که همه term ها وارد summation شوند:

$$\frac{1}{n_1} \sum_{y_i \in Y_1} y_i^2 = \frac{1}{n_1 n_2} \sum_{y_i \in Y_1} y_i^2 \underbrace{\sum_{y_j \in Y_2} 1}_{n_2} =$$

$$\frac{1}{n_1 n_2} \left(\sum_{y_i \in Y_1} \sum_{y_j \in Y_2} y_i^2 \right)$$

به همین ترتیب برای term دوم نیز خواصم داشت:

$$\frac{1}{n_2} \sum_{y_j \in Y_2} y_j^2 = \frac{1}{n_1 n_2} \left(\sum_{y_i \in Y_1} \sum_{y_j \in Y_2} y_j^2 \right)$$

عبارت سوم را هم به همین صورت که بود بازنویسی می کنیم:

$$\frac{-2}{n_1 n_2} \left(\sum_{y_i \in Y_1} \sum_{y_j \in Y_2} y_i y_j \right)$$

$$= \frac{1}{n_1 n_2} \sum_{y_i \in Y_1} \sum_{y_j \in Y_2} (y_i^2 + y_j^2 - 2 y_i y_j) =$$

$$\frac{1}{n_1 n_2} \sum_{y_i \in Y_1} \sum_{y_j \in Y_2} (y_i - y_j)^2$$

مانند که دیده شد، دو تقریب J ارائه شده در سوال با هم معادلند.

Subject,

Year,

Month,

Date,

()

3 الف: فرض کنید M component داریم. پارامترهای عبارت اندازه: $\alpha_1, \dots, \alpha_K$
 $\lambda_1, \dots, \lambda_K$

$$P(n_i | \theta) = \sum_{k=1}^M \alpha_k \text{Poisson}(n_i | \lambda_k) \quad \text{I} \quad \text{observed } n_i$$

$$P(n_i, z_i | \theta) = \prod_{k=1}^M (\alpha_k \text{Poisson}(n_i | \lambda_k))^{z_{ik}} \quad \text{II} \quad \text{hidden } z_i$$

$z_{ik} = 1$
 همانند جزوه درس، z_i یک بردار M تایی است بطوریکه مقدار اندیس k ام مقدار 1 دارد و بقیه اندیس ها مقدار 0 دارند.

حال عبارت maximum likelihood را می نویسیم:

$$\hat{\theta} = \arg \max_{\theta} E_{z | n, \theta} \left[\sum_{i=1}^N \log P(n_i, z_i | \theta) \right] \quad \text{II}$$

$$E_{z | n, \theta} \left[\sum_{i=1}^N \log \prod_{k=1}^M (\alpha_k \text{Poisson}(n_i | \lambda_k))^{z_{ik}} \right] =$$

w.t. $\sum_{k=1}^M \alpha_k = 1$

$$E_{z | n, \theta} \left[\sum_{i=1}^N \sum_{k=1}^M (z_{ik} \log \alpha_k + z_{ik} \log (\text{Poisson}(n_i | \lambda_k))) \right]$$

این را می توانی
 خطی است

$$\sum_{i=1}^N \sum_{k=1}^M (E[z_{ik}] \log \alpha_k + E[z_{ik}] \log (\text{Poisson}(n_i | \lambda_k)))$$

z_{ik} is a boolean variable
 حال $E_{z | n, \theta} [z_{ik}]$ را بدست می آوریم:

$$\Rightarrow E_{z | n, \theta} [z_{ik}] = P(z_{ik} = 1 | n_i, \theta) = \frac{P(n_i | z_{ik} = 1, \theta) P(z_{ik} = 1 | \theta)}{P(n_i | \theta)} \quad \text{I}$$

$$\Rightarrow E_{z | n, \theta} [z_{ik}] = \frac{\text{Poisson}(n_i | \lambda_k) \alpha_k}{\sum_{k=1}^M \alpha_k \text{Poisson}(n_i | \lambda_k)} = \gamma_{ik}$$

حال $E_{z | n, \theta} [z_{ik}]$ را بدست آوریم، آنرا در رابطه Expectation maximization می نوازیم.

$$= \gamma_{ik}$$

PAPCO

$$E_z [L(\theta)] = \sum_{i=1}^N \sum_{k=1}^M (\delta_{ik} \log(\alpha_k) + \delta_{ik} \log(\text{Poisson}(n_i | \lambda_k)))$$

حال باید از $E_z[L(\theta)]$ نسبت به θ (پارامترهای α_k و λ_k) مشتق بگیریم. از آنجا که برای α_k قید داریم $(\sum \alpha_k = 1)$ ، باید تابع لاگرانژ را تشکیل دهیم:

$$L = E_z [L(\theta)] - \lambda \left(\sum_{k=1}^M \alpha_k - 1 \right)$$

$$\Rightarrow \frac{\partial L}{\partial \alpha_k} = 0 \Rightarrow \frac{\partial}{\partial \alpha_k} \left[\sum_{i=1}^N \sum_{k=1}^M \delta_{ik} \log(\alpha_k) \right] -$$

$$\frac{\partial}{\partial \alpha_k} \left[\lambda \sum_{k=1}^M \alpha_k \right] = 0 \Rightarrow$$

$$\sum_{i=1}^N \frac{\delta_{ik}}{\alpha_k} - \lambda = 0 \Rightarrow \alpha_k = \frac{\sum_{i=1}^N \delta_{ik}}{\lambda}$$

$$\sum_{k=1}^M \alpha_k = 1 = \frac{\sum_{k=1}^M \sum_{i=1}^N \delta_{ik}}{\lambda} \Rightarrow \lambda = \sum_{k=1}^M \sum_{i=1}^N \delta_{ik} \Rightarrow$$

$$\alpha_k = \frac{\sum_{i=1}^N \delta_{ik}}{\sum_{k=1}^M \sum_{i=1}^N \delta_{ik}} = \frac{\sum_{i=1}^N \delta_{ik}}{N}$$

اما برای پارامتر λ_k قید نداریم، بنابراین به Lagrangian نسبت:

$$\frac{\partial E_z [L(\theta)]}{\partial \lambda_k} = \frac{\partial}{\partial \lambda_k} \left(\sum_{i=1}^N \delta_{ik} \left(-\lambda_k + n_i \log \lambda_k - \log n_i! \right) \right) = 0$$

$$\Rightarrow - \sum_{i=1}^N \delta_{ik} + \sum_{i=1}^N \delta_{ik} \frac{n_i}{\lambda_k} = 0 \Rightarrow$$

$$\lambda_k = \frac{\sum_{i=1}^N \delta_{ik} n_i}{\sum_{i=1}^N \delta_{ik}}$$

dan $n \times d$
dan $n \times d$

Subject: _____
Year: _____ Month: _____ Date: _____ ()

3. ب. من داریم حاصل ضرب ماتریس $X_{n \times d}$ و $P_i_{d \times 1}$ برابر تصویر داده‌ها روی

محور i ام PCA خواهد بود. $\text{projected samples on } i\text{th component}$
$$= X_{n \times d} \cdot P_i_{d \times 1}$$

مقیاس تغییر واریانس برای محاسبه $\text{Var}(X P_i) = (X P_i)^T (X P_i) = P_i^T X^T X P_i$ داده $X P_i$:

حال باید ثابت کنیم:
$$\lambda_i = P_i^T X^T X P_i$$

برای این کار، از تعریف ماتریس کوارانس استفاده می‌کنیم: تعداد component ها (بردارهای ویژه)

$$(C_{d \times d} = \sum_{i=1}^d \lambda_i P_i P_i^T) \times P_i \rightarrow C P_i = \sum_{i=1}^d \lambda_i P_i P_i^T P_i$$


(این مقدار برای هر $i \neq 1$ صفر است (بردارهای ویژه برهم نهد))


$$\Rightarrow C P_i = \lambda_i \underbrace{P_i P_i^T P_i}_{\|P_i\|^2=1} \Rightarrow C P_i = \lambda_i P_i$$

همین مقیاس تغییر $P_i^T \times (C P_i = \lambda_i P_i) \Rightarrow P_i^T C P_i = \lambda_i \underbrace{P_i^T P_i}_1$

$$\Rightarrow \boxed{P_i^T X^T X P_i = \lambda_i} \quad C = X^T X$$

(4) الف: مدل با مناسب نیست زیرا در جاهایی از قضا که احتمال صفر است (نمونه‌ای

وجود ندارد) این مدل احتمال قابل توجهی میدهد (در شکل با  نشان داده شده‌اند).



مدل ب

اما مدل الف مناسبتر است زیرا مقادیر میانگین و واریانس اوداریش

مربوط به component ها بلرزه هستند که در جاهایی که نمونه‌ای

ندارد $E_{Z|n,\theta} [z_{ik}]$ (امید ریاضی تلفظ نموده m به $cluster\ K$)

نیز نزدیک صفر است.

4 ب: خروجی ب γ نتیجه اولین گام استفاده از EM با component ها نویسی (GMM) باشد.

عنی توانی

دین آن نیست که مقادیر μ و σ^2 در الگوریتم GMM بگونه‌ای update میشوند که

میانگین component ها نویسی می‌باشد با density بالا بنشیند و نویسی با استفاده از μ

با سایر نقاط در فضای density کمتر نویسی داده خواهند شد.

اما همانقدر که دیده میشود در شکل ب میانگین‌های توزیع نویسی در فضاهایی امتداد اند

که $E_{Z|n,\theta} [z]$ صفر است! پس بدستی update نده اند و شکل الف clustering



در update کردن μ و σ^2 ها مناسبتر است.

میانگین نویسی با density صفر